

Project Specification (PS)

Scopo del documento

Il presente documento definisce le specifiche tecniche del progetto di Open Data Management e costituisce la **fonte di verità (Single Source of Truth)** per tutte le attività di progettazione, implementazione e validazione.

Il documento descrive in maniera dettagliata l'architettura della pipeline, i requisiti funzionali e non funzionali, gli standard adottati, gli artefatti attesi e le metodologie da seguire durante l'intero ciclo di sviluppo.

Non contiene implementazioni software, ma esclusivamente specifiche progettuali.

Obiettivo del progetto

Realizzare una pipeline completa di integrazione di Open Data utilizzando dataset della World Bank relativi ai Paesi del mondo.

L'obiettivo finale è trasformare dataset aperti a basso livello (1-3 stelle) in un dataset Linked Open Data conforme al modello a **5 stelle di Tim Berners-Lee**.

L'intero progetto dovrà rispettare gli standard internazionali relativi a:

- Open Data
 - FAIR Data Principles
 - Linked Open Data
 - W3C Best Practices
 - RDF
 - RDFS
 - OWL
 - SKOS
 - DCAT-AP
 - Dublin Core
 - Data Catalog Vocabulary (DCAT)
 - URI Design Best Practices
-

Dataset utilizzati

I dataset provengono dalla World Bank e descrivono indicatori socioeconomici riferiti ai Paesi del mondo.

Le variabili principali sono:

- Population Density
- GDP per Capita
- CO₂ Emissions
- Life Expectancy at Birth

Il codice **ISO 3166 Alpha-3** rappresenta l'identificatore univoco dei Paesi e costituisce la chiave primaria globale per l'intero processo di integrazione.

Architettura generale del progetto

L'intero progetto è concepito come una pipeline modulare composta da fasi indipendenti ma strettamente collegate.

Ogni fase produce un output che rappresenta l'input della fase successiva.

Pipeline generale:

Raw World Bank Dataset

↓

Dataset Analysis

↓

Data Cleaning

↓

Data Refinement

↓

Data Integration

↓

Synthetic Index

↓

Metadata Enrichment

↓

RDF Transformation



Ontology Design



SHACL Validation



Interlinking



Linked Open Data Publication

1. Analisi preliminare dei dataset

Obiettivo

Comprendere struttura, qualità e caratteristiche dei dataset prima di qualsiasi trasformazione.

Attività

Per ciascun dataset devono essere analizzati:

- struttura
- formato
- dimensione
- schema
- tipi di dato
- metadati disponibili
- licenza
- frequenza di aggiornamento
- completezza
- accuratezza
- consistenza
- qualità complessiva

Output

Per ogni dataset dovrà essere prodotto un report contenente:

- descrizione
- criticità individuate

- anomalie
- raccomandazioni

Strumenti consigliati

- Python
- Pandas
- Jupyter Notebook
- Data Profiling Tools

Criticità

- metadati incompleti
- dati mancanti
- codifiche differenti
- incoerenza tra dataset

2. Data Cleaning

Obiettivo

Garantire qualità, consistenza e affidabilità dei dati.

Operazioni previste

- gestione dei valori nulli
- rimozione dei duplicati
- uniformazione dei tipi di dato
- normalizzazione dei nomi delle colonne
- validazione dei codici ISO-3
- rimozione di record inconsistenti
- gestione degli outlier
- verifica dell'integrità dei dati
- controllo delle unità di misura

Per ogni operazione devono essere descritti:

- obiettivo
 - motivazione
 - input
 - output
 - metodologia
 - strumenti consigliati
 - criticità
 - possibili alternative
-

3. Data Refinement

Obiettivo

Preparare i dataset per il processo di integrazione.

Attività

- selezione delle colonne rilevanti
- rinomina delle feature
- standardizzazione delle unità
- trasformazioni
- normalizzazione
- eventuale feature engineering
- preparazione degli schemi

Output

Dataset raffinati e pronti per il merge.

4. Data Integration

Obiettivo

Integrare i dataset in un unico dataset coerente.

Specifiche

Chiave primaria:

ISO-3166 Alpha-3

Tipo di join:

preferibilmente Left Join oppure Full Outer Join, motivando la scelta.

Devono essere affrontati:

- gestione dei record mancanti
- conflitti tra dataset
- verifica delle cardinalità
- controlli di consistenza
- validazione finale

Output

Dataset integrato.

5. Analisi e progettazione dei metadati

Analisi iniziale

Valutare:

- qualità
- completezza
- accuratezza
- conformità agli standard

Nuovo schema metadati

Progettare metadati conformi a:

- Dublin Core
- DCAT
- DCAT-AP

Per ogni elemento descrivere:

- nome
 - descrizione
 - URI
 - cardinalità
 - obbligatorietà
 - esempio
-

6. Progettazione dell'indice sintetico

Obiettivo

Definire un nuovo indicatore sintetico capace di rappresentare il livello di sviluppo complessivo dei Paesi.

Variabili

- GDP per Capita
- Population Density
- CO₂ Emissions
- Life Expectancy

Requisiti

L'indice non dovrà essere una semplice media.

Dovrà prevedere:

- normalizzazione (Min-Max oppure Z-Score)
- identificazione del verso beneficio/costo
- eventuale pesatura
- motivazione metodologica

Devono essere proposte almeno tre formulazioni differenti.

Per ciascuna:

- formula
- vantaggi
- limiti
- robustezza
- interpretabilità

Infine dovrà essere effettuato un confronto critico tra le alternative.

7. Modellazione RDF

Obiettivo

Trasformare il dataset finale in RDF.

Specifiche

Definire:

- namespace
- URI pattern
- identificatori persistenti
- classi
- datatype properties
- object properties
- datatype RDF
- convenzioni di naming

Dominio di esempio:

<https://lod.opendataproject.example/>

Devono essere forniti esempi di triple RDF in formato Turtle.

8. Ontologia OWL

L'ontologia dovrà comprendere almeno le seguenti classi:

- Country
- Dataset
- Observation
- Indicator
- Metadata

Per ciascuna classe descrivere:

- definizione
- relazioni
- datatype properties
- object properties
- vincoli
- cardinalità

Riutilizzare ove possibile vocabolari standard.

9. Mapping CSV → RDF

Progettare il mapping tra il dataset tabellare e il modello RDF.

Per ogni colonna specificare:

- sorgente
- destinazione RDF
- proprietà utilizzata
- datatype
- URI generata

Il mapping dovrà essere rappresentato anche mediante tabelle esplicative.

10. Validazione RDF

Definire una strategia di validazione mediante SHACL.

Descrivere:

- Node Shapes
- Property Shapes
- datatype ammessi
- cardinalità
- vincoli obbligatori

- vincoli opzionali
-

11. Interlinking

Definire la strategia di collegamento verso dataset esterni.

Prevedere almeno:

- DBpedia
- Wikidata

Facoltativamente:

- GeoNames

Motivare l'utilizzo di:

- owl:sameAs
- skos:exactMatch
- rdfs:seeAlso

Descrivere eventuali strumenti automatici di record linkage.

12. Architettura della pipeline

Rappresentare la pipeline mediante diagramma testuale.

Raw CSV

↓

Cleaning

↓

Refinement

↓

Integration

↓

Synthetic Index

↓

Metadata Enrichment



RDF



Ontology



SHACL Validation



Interlinking



Linked Open Data

13. Deliverable previsti

Il progetto dovrà produrre almeno i seguenti artefatti:

- dataset originali
 - dataset puliti
 - dataset raffinati
 - dataset integrato
 - dataset finale
 - indice sintetico
 - catalogo metadati
 - file RDF
 - ontologia OWL
 - mapping CSV → RDF
 - file SHACL
 - URI Specification
 - documentazione tecnica
 - README del progetto
-

14. Versionamento

Tutti gli artefatti dovranno essere versionati.

Ogni versione dovrà riportare:

- numero di versione
 - data
 - descrizione delle modifiche
 - autore
-

15. Best Practices

L'intero progetto dovrà rispettare le migliori pratiche relative a:

Open Data

- dati aperti
- licenze aperte
- interoperabilità

FAIR Data

- Findable
- Accessible
- Interoperable
- Reusable

Linked Open Data

- URI persistenti
- RDF
- collegamenti esterni
- riuso di vocabolari

Data Quality

- completezza
- accuratezza
- consistenza
- validazione

Metadata Management

- metadati standardizzati
- catalogazione
- descrizione semantica

URI Design

- URI persistenti
- URI dereferenziabili

- naming coerente

Semantic Web

- RDF
- RDFS
- OWL
- SKOS
- SHACL

Reproducibility

Ogni fase della pipeline dovrà essere documentata e riproducibile.

Versioning

Ogni artefatto dovrà essere tracciabile nel tempo.

Requisiti generali

Ogni fase del progetto dovrà riportare almeno:

- obiettivo
- input
- output
- prerequisiti
- metodologia
- strumenti consigliati
- criticità
- possibili alternative
- criteri di validazione

Ogni scelta progettuale dovrà essere motivata.

Il progetto dovrà privilegiare:

- modularità;
- interoperabilità;
- riusabilità;
- estendibilità;
- conformità agli standard;
- chiarezza documentale.

L'obiettivo finale è ottenere una pipeline completa di Open Data Management capace di trasformare dataset aperti in Linked Open Data di qualità, conformi ai principi FAIR e alle raccomandazioni del W3C, fornendo una base solida e completamente documentata per l'implementazione del progetto.