

Global Metrics Project

Relazione Finale

Relazione tecnica estesa basata sul progetto di Open Data Management.

Progetto realizzato dallo studente Mattia Edoardo Maria Guarneri, matricola 0766673,
indirizzo email: mattiaedoardomaria.guarneri@community.unipa.it

Indice

- 1. **Introduzione**
- 2. **Dataset, preparazione dei dati e pipeline di integrazione**
- 3. **Architettura software e implementazione della pipeline**
- 4. **Costruzione del Knowledge Graph**
- 5. **Ontologia**
- 6. **Interlinking**
- 7. **Conclusioni**
- **Bibliografia**
- **Sitografia**

1. Introduzione

1.1 Contesto del progetto

La crescente disponibilità di dati aperti ha trasformato il modo in cui istituzioni pubbliche, organizzazioni internazionali e centri di ricerca producono e condividono informazioni. Negli ultimi anni il paradigma degli Open Data ha assunto un ruolo sempre più rilevante all'interno della comunità scientifica e industriale, favorendo la diffusione di dataset liberamente accessibili, documentati e riutilizzabili per attività di analisi, ricerca e supporto ai processi decisionali.

Nonostante questa ampia disponibilità di dati, la semplice pubblicazione di un dataset non è sufficiente a garantirne un utilizzo efficace. I dati aperti vengono infatti distribuiti attraverso formati differenti, possono presentare problemi di qualità, ridondanze, valori mancanti oppure utilizzare convenzioni eterogenee per rappresentare le stesse informazioni. Tali problematiche rendono spesso necessario un processo preliminare di preparazione, normalizzazione e integrazione prima che i dati possano essere realmente impiegati per attività di analisi avanzata.

Nel contesto dell'Open Data Management assume quindi particolare importanza la progettazione di pipeline strutturate in grado di automatizzare tutte le operazioni necessarie alla trasformazione dei dati grezzi in informazioni di qualità. Una pipeline ben progettata non si limita alla semplice pulizia dei dataset, ma comprende attività di integrazione, arricchimento semantico, produzione di metadati, modellazione RDF e pubblicazione secondo gli standard del Web Semantico.

Il progetto **Global Metrics** nasce proprio con questo obiettivo: sviluppare una pipeline completa che consenta di trasformare dataset aperti provenienti dalla World Bank in una base di conoscenza strutturata, interoperabile e semanticamente arricchita. Il progetto è stato sviluppato nell'ambito del corso di **Open Data Management** del Corso di Laurea in Intelligenza Artificiale e costituisce un esempio completo di applicazione delle principali metodologie studiate durante il corso.

L'intero processo è stato progettato seguendo un approccio modulare, nel quale ogni fase della pipeline produce un artefatto ben definito che costituisce l'input della fase successiva. Tale organizzazione rende il sistema facilmente estendibile, riproducibile e manutenibile, consentendo inoltre di sostituire o migliorare singoli componenti senza modificare l'architettura complessiva del progetto. Questo approccio riflette i principi di modularità, interoperabilità e tracciabilità richiesti dalle specifiche progettuali.

2. Dataset, preparazione dei dati e pipeline di integrazione

2.1 Selezione delle sorgenti dati

L'intero progetto è stato sviluppato utilizzando dati aperti pubblicati dalla **World Bank Open Data**, una delle principali piattaforme internazionali dedicate alla diffusione di informazioni statistiche riguardanti lo sviluppo economico, sociale e ambientale dei Paesi del mondo. La scelta di questa sorgente è stata motivata dalla qualità dei dataset messi a disposizione, dalla loro ampia copertura geografica e temporale e dalla disponibilità di metadati completi che ne facilitano il riutilizzo.

Tra le migliaia di indicatori disponibili sono stati selezionati quattro dataset rappresentativi di differenti dimensioni dello sviluppo di un Paese:

- Population density (people per km²)
<https://data.worldbank.org/indicator/EN.POP.DNST>
- GDP per capita (current US\$)
<https://data.worldbank.org/indicator/NY.GDP.PCAP.CD>
- Life expectancy at birth (years)
<https://data.worldbank.org/indicator/SP.DYN.LE00.IN>
- CO₂ emissions (metric tons per capita)
<https://www.climatewatchdata.org/ghg-emissions>

La scelta di questi indicatori non è casuale. Essi descrivono aspetti complementari della realtà socioeconomica mondiale e permettono di osservare contemporaneamente fenomeni demografici, economici, sanitari e ambientali. Considerati nel loro insieme, tali indicatori consentono di costruire una rappresentazione multidimensionale dello stato di sviluppo delle diverse nazioni.

Tutti i dataset vengono distribuiti dalla World Bank in formato CSV accompagnati da documentazione descrittiva, codici identificativi degli indicatori e metadati relativi alla provenienza delle informazioni. Sebbene il formato CSV garantisca un'elevata interoperabilità, esso rappresenta solamente il secondo livello del modello delle 5 stelle degli Open Data e non fornisce alcuna descrizione semantica delle informazioni contenute.

Per questo motivo il progetto si pone l'obiettivo di trasformare questi dataset in una rappresentazione RDF collegata ad altre basi di conoscenza, incrementandone significativamente il livello di riusabilità.

2.2 Analisi preliminare dei dataset

Prima di procedere con qualsiasi attività di integrazione è stata effettuata un'analisi esplorativa dei dataset, finalizzata a comprenderne la struttura e ad individuare eventuali criticità.

Tutti i dataset condividono una struttura molto simile. Ogni record identifica una specifica nazione attraverso il nome del Paese e il relativo codice ISO, mentre i valori degli indicatori sono organizzati in colonne corrispondenti ai diversi anni di osservazione.

Questa organizzazione, pur essendo molto efficiente per la distribuzione dei dati, non risulta particolarmente adatta alle successive operazioni di integrazione e modellazione semantica. La presenza di centinaia di colonne temporali rende infatti difficoltose le operazioni di join tra dataset differenti e complica la trasformazione verso strutture RDF orientate alle entità.

L'analisi preliminare ha inoltre evidenziato alcune problematiche tipiche dei dataset statistici internazionali:

- presenza di valori mancanti per alcuni Paesi e alcuni anni;
- differenze nella disponibilità temporale dei diversi indicatori;
- utilizzo di codifiche differenti per territori particolari;
- necessità di uniformare le denominazioni dei Paesi.

Queste osservazioni hanno guidato la progettazione delle successive fasi della pipeline, orientando le strategie di pulizia e trasformazione dei dati.

2.3 Processo di pulizia e normalizzazione

Una volta analizzata la struttura dei dataset è stato progettato un processo di pulizia finalizzato a produrre un insieme di dati coerente, omogeneo e facilmente integrabile.

La prima operazione consiste nella rimozione delle colonne non necessarie all'analisi. I dataset originali contengono infatti numerosi metadati utili alla consultazione ma ridondanti per gli obiettivi del progetto. Successivamente vengono selezionati esclusivamente gli anni di interesse e vengono eliminati eventuali record incompleti o privi delle informazioni essenziali.

Particolare attenzione è stata dedicata alla gestione dei valori mancanti. Poiché i quattro indicatori presentano coperture temporali differenti, non tutti i Paesi dispongono di osservazioni complete per ogni anno. La pipeline individua automaticamente tali situazioni e mantiene solamente i record che soddisfano i criteri minimi di qualità stabiliti durante la progettazione.

Un ulteriore passaggio riguarda la normalizzazione delle informazioni identificative. I nomi dei Paesi vengono uniformati utilizzando i codici ISO come identificatori principali, riducendo così le ambiguità che potrebbero compromettere le operazioni di integrazione tra dataset differenti.

Questa fase produce dataset caratterizzati da una struttura uniforme e da una qualità significativamente superiore rispetto ai dati originali, costituendo la base per le successive trasformazioni.

2.4 Integrazione dei dataset

Terminata la fase di pulizia, i quattro dataset vengono progressivamente integrati all'interno di un'unica struttura dati.

L'integrazione viene effettuata utilizzando il codice ISO del Paese come chiave primaria, garantendo una corrispondenza univoca tra le osservazioni provenienti dai diversi indicatori. Tale scelta evita possibili errori dovuti alle differenti convenzioni utilizzate per rappresentare i nomi delle nazioni.

Durante questa fase vengono inoltre allineati gli intervalli temporali e viene selezionato l'insieme di osservazioni condivise da tutti gli indicatori considerati. In questo modo ogni record finale rappresenta una descrizione completa di un determinato Paese in uno specifico anno.

Il risultato dell'integrazione è un dataset consolidato che riunisce informazioni economiche, demografiche, ambientali e sanitarie all'interno di una singola struttura coerente. Questo dataset costituisce il punto di partenza per tutte le successive elaborazioni statistiche e per la costruzione del Knowledge Graph.

2.5 Arricchimento dei dati

Una caratteristica distintiva del progetto consiste nell'introduzione di una fase di arricchimento delle informazioni.

Oltre ai dati originariamente presenti nei dataset della World Bank, la pipeline genera nuove informazioni derivate mediante elaborazioni automatiche. Tra queste rientrano indicatori sintetici, statistiche descrittive e collegamenti con risorse esterne del Web Semantico.

L'arricchimento non modifica il significato delle osservazioni originali ma ne aumenta il valore informativo, consentendo di effettuare analisi più articolate e facilitando l'integrazione con altre basi di conoscenza.

In particolare, vengono predisposti gli identificatori che permetteranno successivamente di collegare le entità del progetto a risorse pubbliche come DBpedia e Wikidata, rendendo il dataset parte integrante dell'ecosistema dei Linked Open Data.

2.6 La pipeline di trasformazione

L'intero processo descritto nelle sezioni precedenti è stato implementato mediante una pipeline completamente automatizzata.

Ogni fase della pipeline riceve in ingresso l'output della fase precedente e produce un nuovo artefatto intermedio, riducendo al minimo gli interventi manuali e garantendo la riproducibilità dell'intero workflow.

L'automazione consente inoltre di ripetere l'intero processo ogni volta che vengono pubblicate nuove versioni dei dataset della World Bank, senza modificare la logica dell'applicazione. Questo rappresenta uno degli aspetti più importanti del progetto, poiché dimostra come i principi dell'Open Data Management possano essere applicati attraverso soluzioni software modulari e facilmente estendibili.

La pipeline realizzata costituisce quindi il collegamento tra i dati grezzi forniti dalla sorgente originale e il Knowledge Graph RDF che verrà descritto nei capitoli successivi, rappresentando il nucleo operativo dell'intero progetto.

3. Architettura software e implementazione della pipeline

3.1 Obiettivi progettuali

Uno degli obiettivi principali del progetto non era soltanto quello di elaborare un insieme di dataset della World Bank, ma anche quello di sviluppare una soluzione software riutilizzabile per la realizzazione di pipeline di Open Data Management.

Per questo motivo si è scelto di evitare la realizzazione di un semplice insieme di script indipendenti, privilegiando invece un'architettura modulare organizzata come una vera e propria libreria Python. Questa scelta consente di separare chiaramente le responsabilità delle diverse componenti del sistema, migliorando la manutenibilità del codice e favorendone il riutilizzo in progetti futuri.

La progettazione è stata guidata da alcuni principi fondamentali dell'ingegneria del software:

- modularità;
- separazione delle responsabilità (Separation of Concerns);
- estensibilità;
- riusabilità;
- riproducibilità delle elaborazioni.

Grazie a questi principi, ogni componente della pipeline può essere sviluppato, testato e modificato indipendentemente dagli altri, riducendo l'accoppiamento tra i moduli e facilitando l'evoluzione del sistema.

3.2 La libreria *opendata_flowlib*

Il cuore del progetto è rappresentato dalla libreria **opendata_flowlib**, sviluppata per raccogliere tutte le funzionalità necessarie alla gestione dell'intero workflow di elaborazione dei dati.

La libreria è organizzata in diversi moduli specializzati, ciascuno dedicato a una specifica fase della pipeline.

Tra i principali componenti si possono individuare:

- moduli per l'acquisizione dei dataset da sorgenti locali o remote;

- componenti per la pulizia e la normalizzazione dei dati;
- strumenti per la trasformazione delle strutture tabellari;
- moduli dedicati all'arricchimento delle informazioni;
- componenti per la produzione di visualizzazioni;
- funzionalità per la costruzione del grafo RDF;
- strumenti per l'esecuzione delle interrogazioni SPARQL.

Questa organizzazione permette di mantenere ogni funzionalità indipendente dalle altre, favorendo il riutilizzo dei singoli moduli anche in pipeline differenti.

La libreria costituisce quindi il livello applicativo del progetto, mentre gli script presenti nella cartella principale rappresentano esempi concreti di utilizzo delle funzionalità implementate.

3.3 Organizzazione del progetto

L'intero repository è stato organizzato seguendo una struttura che separa chiaramente il codice sorgente, i dati di input, gli artefatti elaborati e la documentazione tecnica.

Le principali directory possono essere così sintetizzate:

- **opendata_flowlib/** contiene la libreria Python che implementa i moduli di lettura, pulizia, trasformazione, arricchimento semantico e serializzazione dei dati;
- **scripts/** raccoglie gli script utilizzati per orchestrare le diverse fasi della pipeline, dalla preparazione dei dataset alla generazione delle visualizzazioni fino alla costruzione del Knowledge Graph RDF;
- **raw_data/** ospita i file CSV originali scaricati dalla World Bank, mantenendo inalterati i dati di partenza;
- **processed/** contiene gli output prodotti dalla pipeline, tra cui i dataset puliti, i file integrati, gli artefatti RDF e gli altri risultati intermedi e finali;
- **lookup_data/** conserva i file di mapping utilizzati durante le operazioni di arricchimento semantico e di risoluzione delle entità;
- **charts/** raccoglie i grafici, le mappe e le visualizzazioni generate nel corso delle analisi;
- **docs/** include la documentazione tecnica relativa all'architettura, al workflow e alle principali componenti del progetto.

Questa organizzazione consente di distinguere chiaramente il software riutilizzabile dagli artefatti prodotti durante l'elaborazione, migliorando la leggibilità complessiva del repository.

L'utilizzo di una struttura ordinata facilita inoltre la manutenzione del progetto e rende immediatamente individuabili le diverse componenti dell'applicazione.

3.4 Il motore della pipeline

L'intera sequenza di elaborazione viene orchestrata mediante un motore di pipeline progettato secondo il paradigma della **Fluent Interface**.

Questo approccio consente di descrivere le operazioni attraverso una sequenza ordinata di chiamate concatenate, rendendo il workflow particolarmente leggibile e vicino alla rappresentazione concettuale del processo di elaborazione.

Ogni fase della pipeline riceve un dataset in ingresso, applica una trasformazione specifica e restituisce il risultato alla fase successiva.

L'esecuzione può comprendere operazioni quali:

- caricamento dei dataset;
- filtraggio delle osservazioni;
- normalizzazione delle colonne;
- integrazione delle sorgenti;
- generazione di nuovi attributi;
- esportazione dei risultati;
- costruzione del grafo RDF.

Questa modalità di progettazione rende estremamente semplice inserire nuove trasformazioni o sostituire quelle esistenti senza modificare il resto dell'applicazione.

Un ulteriore vantaggio consiste nella completa riproducibilità dell'intero workflow: eseguendo la pipeline sugli stessi dati di ingresso si ottengono sempre gli stessi risultati, caratteristica fondamentale nei processi di gestione dei dati.

3.5 Componenti principali

La pipeline è composta da numerosi moduli cooperanti, ciascuno responsabile di una specifica attività.

I moduli dedicati all'importazione gestiscono la lettura dei dataset e la loro conversione in strutture dati utilizzabili dalle elaborazioni successive.

Le componenti di trasformazione implementano invece tutte le operazioni di pulizia, selezione e normalizzazione delle informazioni.

Una parte rilevante del sistema è dedicata alla produzione automatica di visualizzazioni statistiche e grafici, utili sia durante la fase esplorativa sia per documentare i risultati ottenuti.

I moduli semantici rappresentano invece il collegamento tra il mondo tabellare e quello del Semantic Web. Essi si occupano della generazione delle triple RDF, dell'assegnazione degli URI e della serializzazione finale del Knowledge Graph.

Infine, specifici componenti consentono l'esecuzione di interrogazioni SPARQL sul grafo prodotto, permettendo di verificare la correttezza della modellazione e di estrarre informazioni secondo differenti criteri di ricerca.

L'elevata coesione interna di ciascun modulo e il basso accoppiamento tra le componenti costituiscono uno degli aspetti più significativi dell'architettura sviluppata.

3.6 Considerazioni progettuali

L'architettura realizzata rappresenta un compromesso tra semplicità implementativa e flessibilità; essa adotta numerosi principi tipici delle applicazioni software professionali, tra cui la modularizzazione del codice, la separazione delle responsabilità, la configurabilità della pipeline e la riusabilità dei componenti.

L'organizzazione della libreria consente inoltre di estendere facilmente il sistema con nuovi dataset o ulteriori esportazioni senza modificare la struttura esistente.

4. Costruzione del Knowledge Graph

4.1 Obiettivi della modellazione RDF

Uno degli obiettivi principali del progetto consiste nella trasformazione dei dati tabellari prodotti dalla pipeline in un Knowledge Graph conforme ai principi del Semantic Web. Sebbene i dataset originali della World Bank siano facilmente consultabili in formato CSV, essi non consentono di rappresentare in modo esplicito le relazioni tra le diverse entità né di integrare agevolmente informazioni provenienti da sorgenti differenti.

La modellazione RDF permette di superare questi limiti rappresentando i dati come un insieme di triple **soggetto-predicato-oggetto**, nelle quali ogni risorsa è identificata mediante un URI univoco. Questo approccio rende le informazioni interpretabili non solo dagli utenti, ma anche dalle macchine, favorendo l'interoperabilità con altri dataset pubblicati sul Web.

Nel progetto, il Knowledge Graph rappresenta l'ultima fase della pipeline di elaborazione e costituisce il risultato finale del processo di trasformazione dei dati aperti.

4.2 Modellazione delle entità

La costruzione del grafo parte dall'identificazione delle principali entità presenti nei dataset.

L'entità centrale è rappresentata dal **Paese**, identificato attraverso il codice ISO e associato al relativo URI persistente. Ogni Paese è collegato ai diversi indicatori statistici disponibili, ciascuno dei quali descrive uno specifico aspetto economico, demografico, sanitario o ambientale.

Gli indicatori sono rappresentati come proprietà delle osservazioni e comprendono:

- densità di popolazione;
- PIL pro capite;
- aspettativa di vita;
- emissioni di CO₂ pro capite.

Ogni osservazione mantiene inoltre il riferimento all'anno di rilevazione, consentendo di rappresentare correttamente l'evoluzione temporale dei dati.

Questa modellazione permette di organizzare le informazioni secondo una struttura facilmente estendibile, nella quale nuovi indicatori possono essere aggiunti senza modificare l'organizzazione generale del grafo.

4.3 Generazione degli URI

Per garantire l'univocità delle risorse, ogni entità del Knowledge Graph viene identificata mediante URI persistenti.

La generazione degli URI segue una convenzione uniforme che consente di distinguere chiaramente le diverse tipologie di risorse, quali Paesi, osservazioni e indicatori.

L'utilizzo di identificatori persistenti rappresenta uno degli aspetti fondamentali del Semantic Web, poiché permette di riferirsi alle stesse entità anche da dataset differenti e costituisce il prerequisito necessario per la creazione di collegamenti verso basi di conoscenza esterne.

L'adozione di una convenzione coerente semplifica inoltre la navigazione del grafo e rende immediata l'identificazione delle risorse generate automaticamente dalla pipeline.

4.4 Serializzazione del grafo RDF

Una volta completata la modellazione delle entità, la pipeline provvede alla generazione automatica delle triple RDF.

Ogni record del dataset integrato viene convertito in un insieme di triple che descrivono il Paese, le osservazioni associate e i relativi indicatori.

L'intero processo viene realizzato automaticamente mediante i moduli sviluppati all'interno della libreria *opendata_flowlib*, che trasformano i dati tabellari nella corrispondente rappresentazione semantica.

Il risultato finale consiste in un file RDF serializzato in formato Turtle, facilmente leggibile sia dagli utenti sia dai software dedicati alla gestione dei grafi di conoscenza.

La serializzazione rappresenta il punto di arrivo della pipeline e costituisce la base per tutte le successive interrogazioni sul Knowledge Graph.

4.5 Collegamenti con risorse esterne

Uno degli aspetti più significativi del progetto riguarda l'arricchimento semantico mediante collegamenti verso basi di conoscenza pubbliche.

Per ciascun Paese vengono infatti individuati gli identificatori corrispondenti presenti in risorse esterne come **DBpedia** e **Wikidata**, consentendo di stabilire collegamenti espliciti tra il grafo sviluppato e il più ampio ecosistema dei Linked Open Data.

Questi collegamenti incrementano notevolmente il valore informativo del dataset, permettendo di accedere indirettamente a una grande quantità di informazioni aggiuntive senza doverle duplicare all'interno del progetto.

Dal punto di vista metodologico, questa fase rappresenta il completamento del processo di semantizzazione, poiché trasforma un insieme di dati isolati in un grafo interoperabile e interconnesso con altre basi di conoscenza pubbliche.

4.6 Risultato finale della trasformazione

Al termine della pipeline, i dataset originariamente distribuiti in formato CSV vengono trasformati in un Knowledge Graph RDF completo, nel quale ogni risorsa è identificata mediante URI persistenti e collegata alle altre attraverso relazioni semanticamente esplicite.

Il grafo risultante può essere interrogato mediante il linguaggio SPARQL, consentendo di effettuare ricerche complesse che coinvolgono contemporaneamente più indicatori e più entità.

La trasformazione realizzata dimostra concretamente come un insieme di Open Data tradizionali possa evolvere verso un dataset conforme ai principi dei Linked Open Data, incrementandone l'interoperabilità, la riusabilità e il valore informativo. Il Knowledge Graph prodotto rappresenta quindi il principale risultato dell'intero progetto e costituisce la base per le analisi illustrate nel capitolo successivo.

5. Interrogazione del Knowledge Graph e analisi dei risultati

5.1 Obiettivi dell'interrogazione del grafo

Una volta completata la costruzione del Knowledge Graph RDF, il passo successivo consiste nell'utilizzare la struttura semantica ottenuta per estrarre informazioni significative attraverso interrogazioni complesse. L'obiettivo di questa fase non è soltanto verificare la correttezza della modellazione, ma soprattutto dimostrare il valore aggiunto derivante dall'adozione di un approccio basato su dati collegati.

Rispetto a un tradizionale dataset tabellare, un grafo RDF consente infatti di effettuare interrogazioni multi-dimensionali che combinano simultaneamente più entità, attributi e relazioni, rendendo possibile un livello di analisi non facilmente ottenibile con strumenti standard di data processing.

Le interrogazioni sono state implementate utilizzando il linguaggio **SPARQL**, lo standard del W3C per la query di dati RDF.

5.2 Tipologie di interrogazioni SPARQL

Le query sviluppate nel contesto del progetto possono essere raggruppate in diverse categorie in base all'obiettivo analitico.

Una prima tipologia riguarda le interrogazioni descrittive, finalizzate all'estrazione dei valori di un singolo indicatore per un determinato Paese o intervallo temporale. Queste query permettono di analizzare l'evoluzione storica di variabili come il PIL pro capite o l'aspettativa di vita.

Una seconda categoria comprende le interrogazioni comparative, che consentono di confrontare più Paesi rispetto a uno o più indicatori. Questo tipo di analisi è particolarmente utile per evidenziare differenze strutturali tra aree geografiche o gruppi di Paesi con caratteristiche simili.

Un ulteriore insieme di interrogazioni riguarda invece le analisi multidimensionali, nelle quali vengono combinati contemporaneamente più indicatori. In questo caso il grafo consente di mettere in relazione variabili economiche, demografiche e ambientali, offrendo una visione integrata dello sviluppo dei Paesi.

Infine, alcune query sono state progettate per verificare la coerenza del grafo e la correttezza delle relazioni generate durante la fase di costruzione del Knowledge Graph.

5.3 Analisi dei risultati

L'esecuzione delle interrogazioni SPARQL sul Knowledge Graph ha permesso di ottenere risultati significativi sia dal punto di vista analitico sia dal punto di vista metodologico.

Dal punto di vista dei contenuti, il grafo consente di evidenziare relazioni interessanti tra indicatori differenti. Ad esempio, è possibile osservare correlazioni tra il livello di sviluppo economico di un Paese e la sua aspettativa di vita, oppure tra la densità di popolazione e le emissioni pro capite di CO₂.

Queste analisi, che nel modello tabellare richiederebbero operazioni di join complesse e non sempre efficienti, diventano invece naturali grazie alla struttura semantica del grafo.

Dal punto di vista metodologico, i risultati ottenuti confermano la validità dell'approccio adottato. La trasformazione dei dati in RDF consente infatti di ridurre la complessità delle interrogazioni e di aumentare la flessibilità nell'esplorazione delle informazioni.

6. Ontologia “gmont”

6.1 Struttura dell’ontologia

La struttura dell’ontologia è organizzata per rappresentare in modo formale le relazioni tra i paesi e i loro indicatori socioeconomici, sanitari e ambientali. In particolare, la classe principale **gmont:Country** descrive ogni entità nazionale, mentre le proprietà come **gmont:hasGDPPerCapita**, **gmont:hasPopulationDensity**, **gmont:hasLifeExpectancy** e **gmont:hasCO2Emissions** associano a ciascun paese i valori numerici degli indicatori analizzati. Le proprietà dati sono definite con dominio e range espliciti, così da garantire coerenza semantica e facilità di interrogazione. Inoltre, l’ontologia include una proprietà di interlinking, **gmont:exactMatchDBpedia**, che collega ogni paese alla corrispondente risorsa di DBpedia, rendendo il grafo non solo interno ed esplicito, ma anche interoperabile con altre basi di conoscenza

6.2 Perché solo “Country”?

La scelta di adottare una sola classe principale, **Country**, è motivata dalla necessità di mantenere il modello semplice, leggibile e coerente con il tipo di analisi svolta. Poiché il dataset descrive in modo uniforme gli stessi concetti per ogni entità nazionale, non è stato necessario introdurre classi aggiuntive per rappresentare categorie diverse. In questo contesto, i dati rilevanti sono soprattutto i valori associati a ciascun paese, mentre le relazioni tra le entità sono già espresse attraverso le proprietà dell’ontologia. Questa scelta consente di ridurre la complessità del modello senza compromettere la capacità di descrivere correttamente il dominio.

6.3 Object Property

Nel nostro caso, la principale *object property* è **exactMatchDBpedia**, che mette in relazione ogni paese con la corrispondente risorsa presente in DBpedia. Questa scelta permette di stabilire un legame semantico tra i dati locali e una conoscenza esterna già strutturata, rendendo possibile l’interoperabilità e l’arricchimento delle informazioni.

6.4 Data Property

Oltre alla classe principale **Country**, l’ontologia definisce diverse data property che descrivono i valori quantitativi associati a ciascun paese. Tra queste, **hasGDPPerCapita** indica il PIL pro capite, **hasPopulationDensity** rappresenta la densità della popolazione, **hasLifeExpectancy** descrive l’aspettativa di vita media e **hasCO2Emissions** misura le emissioni di CO₂ pro capite. Queste proprietà permettono di trasformare i dati tabellari in informazioni semanticamente strutturate, rendendo possibile confrontare i paesi in modo chiaro e automatico.

6.5 Resources

Le risorse della base di conoscenza sono rappresentate tramite gli URI contenuti nel namespace `/resources`, che identificano in modo univoco ogni paese del dataset. Ogni risorsa corrisponde a una singola entità reale e viene collegata alle sue proprietà semantiche, come i valori degli indicatori e i riferimenti a fonti esterne. In questo modo, ogni paese non è semplicemente una riga di un file CSV, ma un'entità autonoma e navigabile all'interno del grafo RDF.

7. Conclusioni

7. Analisi finale

In conclusione, i risultati mostrano come l'integrazione di dati aperti, analisi statistica e modellazione semantica abbia permesso di ottenere una visione più completa del problema studiato. L'utilizzo di un indice sintetico, come il **GSWI**, è risultato particolarmente utile perché ha reso possibile confrontare in modo immediato i diversi paesi, evidenziando non solo i casi più ricchi, ma anche quelli più sostenibili e equilibrati. In questo modo, l'indice non ha avuto un ruolo solo descrittivo, ma ha contribuito a organizzare i risultati in maniera chiara, facilitando l'interpretazione delle relazioni tra economia, salute e impatto ambientale

Bibliografia

- World Bank Open Data
- DBpedia
- W3C RDF e RDFS
- OWL Recommendation

Sitografia

<https://data.worldbank.org/>
<https://dbpedia.org/>
<https://www.w3.org/RDF/>